


# 序列 生成

张江

北京师范大学  
系统科学学院

# 我们生活在一个序列的世界

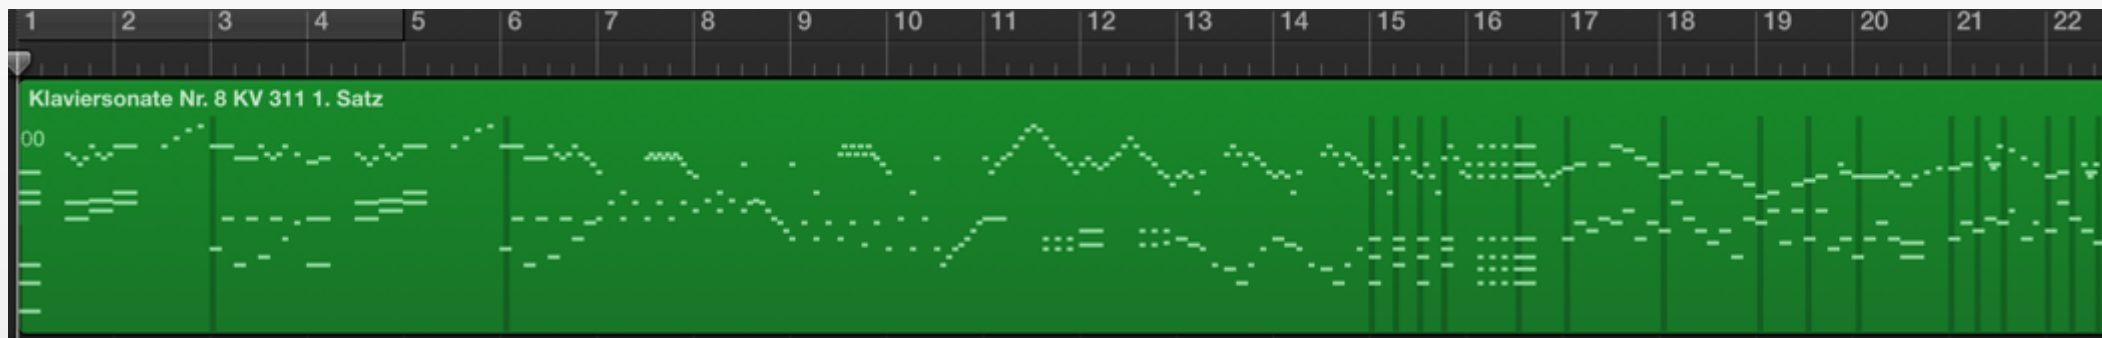


# 序列生成问题




- A yellow bus driving down a road with green trees and green grass in the background.

# 神经网络莫扎特



用莫扎特的原曲作为训练数据，让RNN学习其中的Pattern，然后再让它重新创造一段曲子



# 序列生成问题通用解决方法

## 基本思想


1. 将生成问题转化为一个预测问题;
2. 完成自举过程: 给定一个种子, 不断用已经生成的数据预测下一个数据

序列生成问题通用解决方法： 第一步


我爱北京天安? → 门

## 序列生成问题通用解决方法： 第一步

我爱北京天安?  $\longrightarrow$  门




## 序列生成问题通用解决方法： 第二步



$W_1, W_2, W_3, W_3, W_4$




## 序列生成问题通用解决方法： 第二步



$W_1, W_2, W_3, W_3, W_4, W_5$

## 序列生成问题通用解决方法： 第二步




$W_1, W_2, W_3, W_3, W_4, W_5, W_6$

# RNN

- 隐含层内部存在着连接
- 每一个隐含层单元都与所有其他隐含层单元相连接

$$h_t = \sigma(W_{Xh}X_t + W_{hh}h_{t-1})$$

$$Y_t = \sigma(W_{hY}h_t)$$



# 上下文无关语法生成器

让RNN学会一定的语法:

01  
0011  
0000011111  
000111  
01  
000111  
00000000001111111111

训练数据

$0^n 1^n$

# 为什么要研究这样的语法？

- 它足够简单
- 自然序列中存在着类似的Pattern
  - The evidence was convincing(nv)
  - The evidence the lawyer provided was convincing(nnvv)
  - The evidence the lawyer the gangster retained provided was convincing(nnnvvv)
- 学术价值

下一个数字是几？

0000

下一个数字是几？

00000

下一个数字是几？

000001



下一个数字是几？

0000011

下一个数字是几？

00000111

下一个数字是几？

000001111

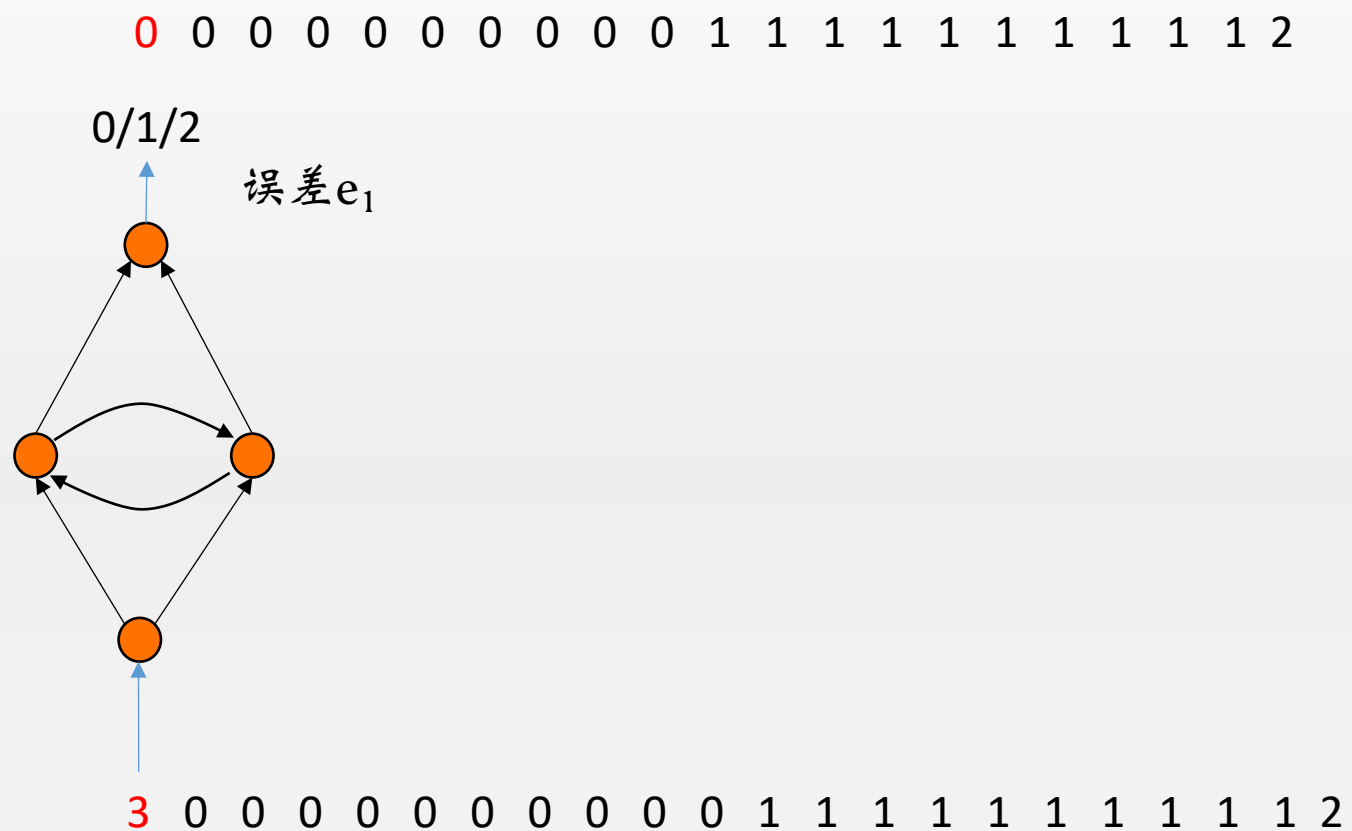
下一个数字是几？

000001111


## 问题的关键点和难度

- 问题的关键点在第一个1出现之后
  - 000001.....
  - 后续的1必然要与前面的0的个数相匹配
- RNN必须自己学会计数
  - n没有显示地表达在输入数字中


# RNN如何工作



# RNN如何工作



# RNN如何工作






# RNN如何工作

0 0 0 0 0 0 0 0 0 0 0 1 **1** 1 1 1 1 1 1 1 1 2

0/1/2

误差 $e_{12}$




3 0 0 0 0 0 0 0 0 0 0 0 **1** 1 1 1 1 1 1 1 1 1 2

# RNN如何工作

0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1 2

0/1/2

误差  $e_{21}$




将每一步的误差  
加总、反传


3 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1 2

# 真正的神经网络

需要将类型变量变成独热（one hot）编码



输出：0，1，2三种可能




输入：0，1，2，3四种可能

# 损失函数

标准答案:

1

Log(0.1) Log(0.8) Log(0.1)




$$L_{t=0} = -\log p_1 = -\log(0.8)$$

# 损失函数


标准答案: 0

Log(0.1) Log(0.5) Log(0.4)



$$L_{t=1} = -\log p_0 = -\log(0.1)$$


# 损失函数



假设序列总长度为 $T$ ，则：

$$L_{\text{总}} = -(\log p_0 + \log p_1 + \log p_2 + \cdots \log p_T)$$

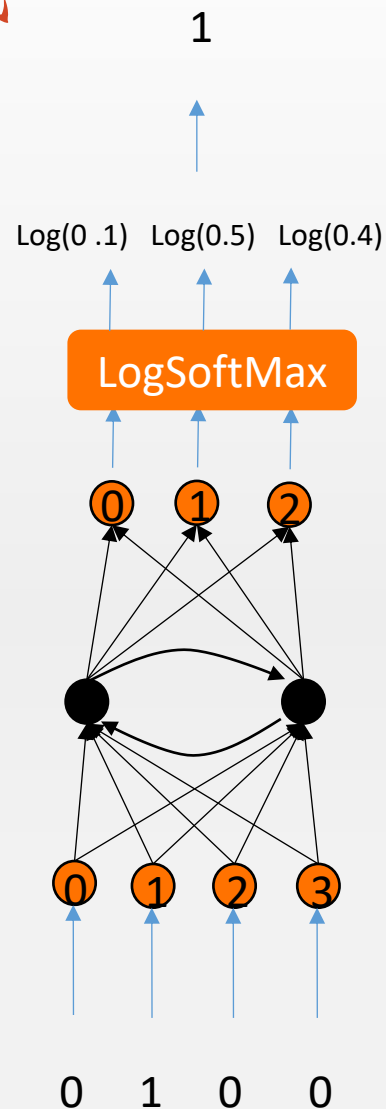
测试效果



n	目标序列	RNN预测	不同的位数量
0	2	0	1
1	012	002	1
2	00112	00012	1
3	0001112	0000112	1
4	000011112	000001112	1
.....	.....	.....	.....
13	000000000000001111111111112	000000000000000111111111112	1
14	00000000000000011111111111112	00000000000000001111111111212	2

N>13以后，开始出现更多的错误，说明2个隐含单元的RNN的记忆容量就是13

## 第二阶段：序列生成



```
torch.multinomial(output.view(-1).exp())
```

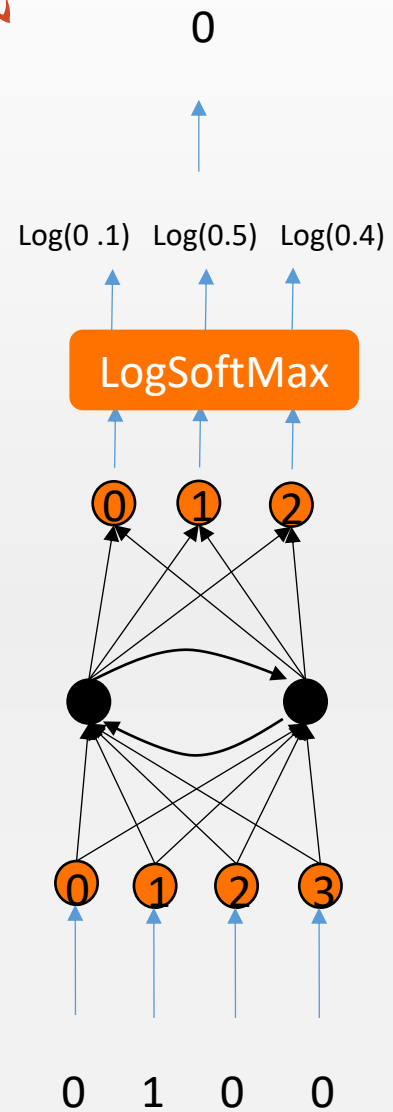
```
output.view(-1).exp():
```

0.1, 0.5, 0.4

`multinomial`依概率 (0.1,0.5,0.4) 投掷骰子，并选择其中一个

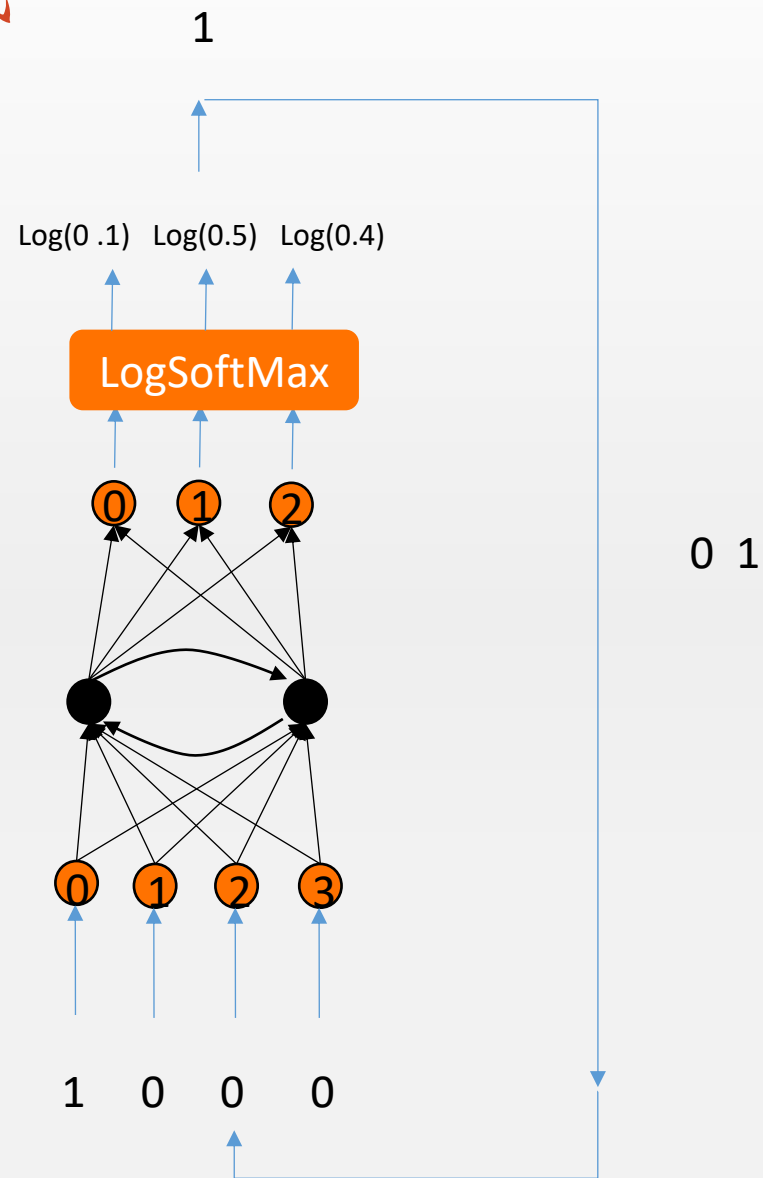


## 第二阶段：序列生成

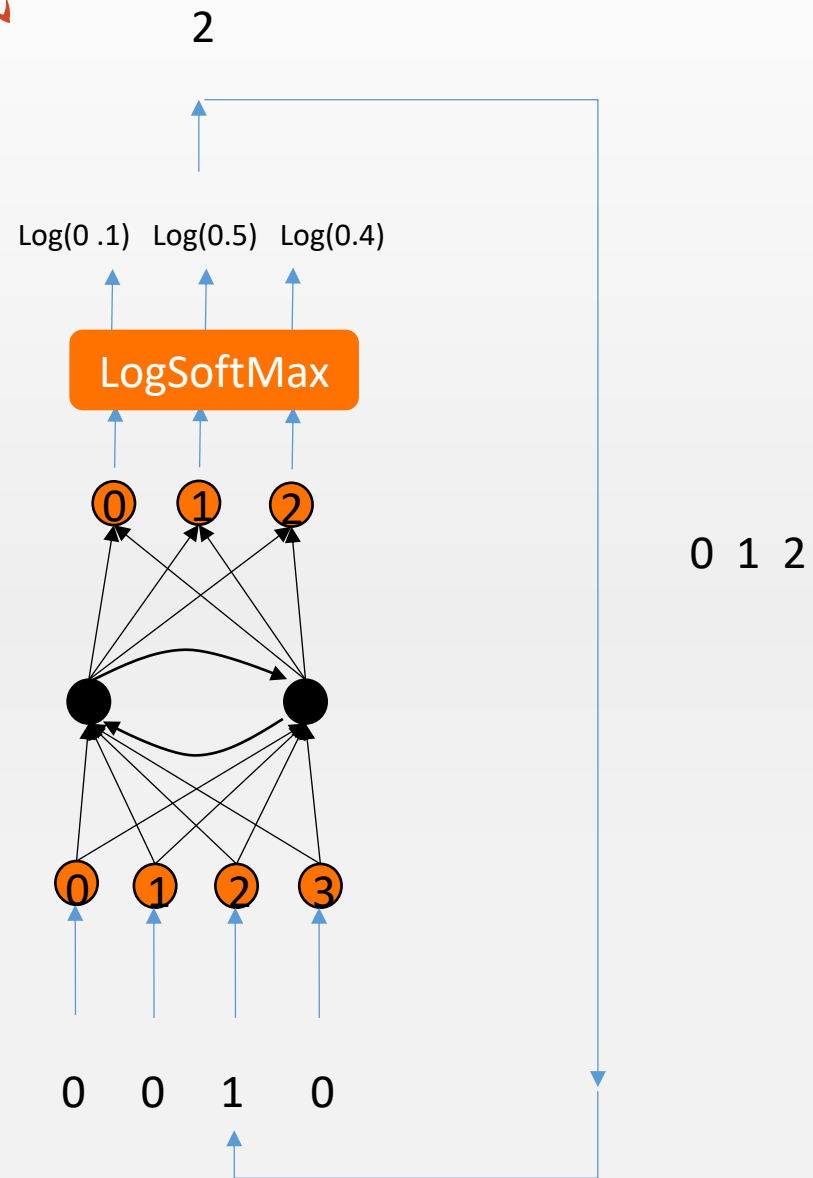


0


## 第二阶段：序列生成



## 第二阶段：序列生成




# RNN的PyTorch实现



```
class SimpleRNN(nn.Module):  
    def __init__(self, input_size, hidden_size, output_size, num_layers = 1):  
        super(SimpleRNN, self).__init__()  
  
        self.hidden_size = hidden_size  
        self.num_layers = num_layers  
        # 一个embedding层  
        self.embedding = nn.Embedding(input_size, hidden_size)  
        # 隐含层内部的相互链接  
        self.rnn = nn.RNN(hidden_size, hidden_size, num_layers, batch_first = True)  
        # 输出的全链接层  
        self.fc = nn.Linear(hidden_size, output_size)  
        # 最后的logsoftmax层  
        self.softmax = nn.LogSoftmax()  
  
    def forward(self, input, hidden):  
  
        # 先进行embedding层的计算，它可以把一个  
        x = self.embedding(input)  
        # 从输入到隐含层的计算  
        output, hidden = self.rnn(x, hidden)  
        # 从输出output中取出最后一个时间步的数值  
        output = output[:, -1, :]  
        # 喂入最后一层全链接网络  
        output = self.fc(output)  
        # softmax函数  
        output = self.softmax(output)  
        return output, hidden
```

# RNN函数的坑



```
self.rnn = nn.RNN(hidden_size, hidden_size, num_layers, batch_first = True)
```

```
output, hidden = self.rnn(x, hidden)
```

- `x`: `batch_size * time_step * input_size`
- `hidden`: `num_layers * batch_size * hidden_size`
- `output`: `time_step * batch_size * hidden_size`

例子:


```
>>> rnn = nn.RNN(10, 20, 2) : 输入单元10, 隐含单元20, 2层
```

```
>>> input = Variable(torch.randn(5, 3, 10)) : 5个时间步, batch_size=3,  
10维的输入向量
```

```
>>> h0 = Variable(torch.randn(2, 3, 20)) : 2层, batch: 3, 隐含单元20
```



```
>>> output, hn = rnn(input, h0): output为一个5*3*20的张量
```

# 解剖这个RNN





# 隐含单元分析

Input: 00112, output: 00012




# 输出层分类器






# 隐含单元分析

Input: 00112, output: 00012




# 隐含单元分析

Input: 00000111112, output:00000011112




# 隐含单元分析

Input: 00000000001111111112,  
output:00000000000111111111



事实上.....



RNN实现了两个动力系统:

$$h_{t+1} = f(h_t) = RNN(0, h_t)$$


$$h_{t+1} = g(h_t) = RNN(1, h_t)$$

这两个动力系统要求:


- f和g的不动点要能被绿色线分开
- 运动的直线为系统的特征向量方向
- f与g的特征值应该互为倒数

P. Rodriguez et al., A Recurrent Neural Network that Learns to Count, Connection Science, Vol. 11, No1, 1999: 5-40


## RNN的痛点：无法完成长程记忆



让我们尝试用LSTM来做




## 解决方案



- 加入内部的存储


## 解决方案



- 加入内部的存储
- 加入遗忘门




## 解决方案



- 加入内部的存储
- 加入遗忘门
- 遗忘门由输入信号控制

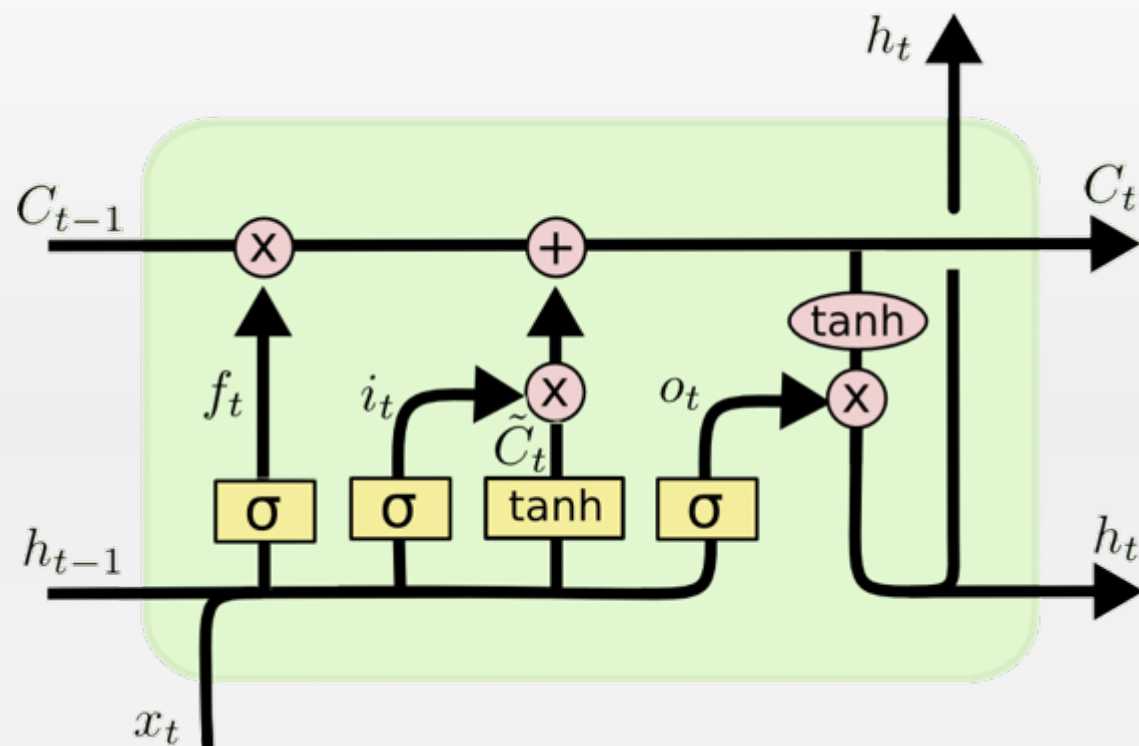
## LSTM一个细胞的结构



$$\begin{aligned}h_{t+1} &= o_t * \tanh(c_t) \\c_{t+1} &= f_t * c_t + i_t * g_t \\g_t &= \tanh(W_{ig}x_t + W_{hc}h_t + b_g)\end{aligned}$$

$$\begin{aligned}i_{t+1} &= \sigma(W_{ii}x_t + W_{hi}h_t + b_i) \\f_{t+1} &= \sigma(W_{if}x_t + W_{hf}h_t + b_f) \\o_{t+1} &= \sigma(W_{io}x_t + W_{ho}h_t + b_o)\end{aligned}$$


## LSTM一个细胞的结构



$$\begin{aligned}h_{t+1} &= o_t * \tanh(c_t) \\c_{t+1} &= f_t * c_t + i_t * g_t \\g_t &= \tanh(W_{ig}x_t + W_{hc}h_t + b_g)\end{aligned}$$

$$\begin{aligned}i_t &= \sigma(W_{ii}x_t + W_{hi}h_t + b_i) \\f_t &= \sigma(W_{if}x_t + W_{hf}h_t + b_f) \\o_t &= \sigma(W_{io}x_t + W_{ho}h_t + b_o)\end{aligned}$$


# 测试效果



n	目标序列	RNN预测	不同的位数量
0	2	0	1
1	012	002	1
2	00112	00012	1
3	0001112	0000112	1
4	000011112	0000011112	1
.....	.....	.....	.....
20	.....	.....	1
21	.....	.....	2



N>20以后，开始出现更多的错误，说明1个LSTM单元的记忆容量就已经达到了20

# 测试效果




# 输出层


输入:  $0^n 1^n$   $n=20$




## 内部状态




$$\begin{aligned}h_{t+1} &= o_t * \tanh(c_t) \\c_{t+1} &= f_t * c_t + i_t * g_t \\g_t &= \tanh(W_{ig}x_t + W_{hc}h_t + b_g)\end{aligned}$$



# LSTM的各个门




$$\begin{aligned}i_t &= \sigma(W_{ii}x_t + W_{hi}h_t + b_i) \\f_t &= \sigma(W_{if}x_t + W_{hf}h_t + b_f) \\o_t &= \sigma(W_{io}x_t + W_{ho}h_t + b_o) \\g_t &= \tanh(W_{ig}x_{t-1} + W_{hg}h_{t-1} + b_g) \\c_t &= f_t * c_{t-1} + i_{t-1} * g_{t-1}\end{aligned}$$





## 神经网络莫扎特



## 基本步骤



# MIDI音乐与MIDO

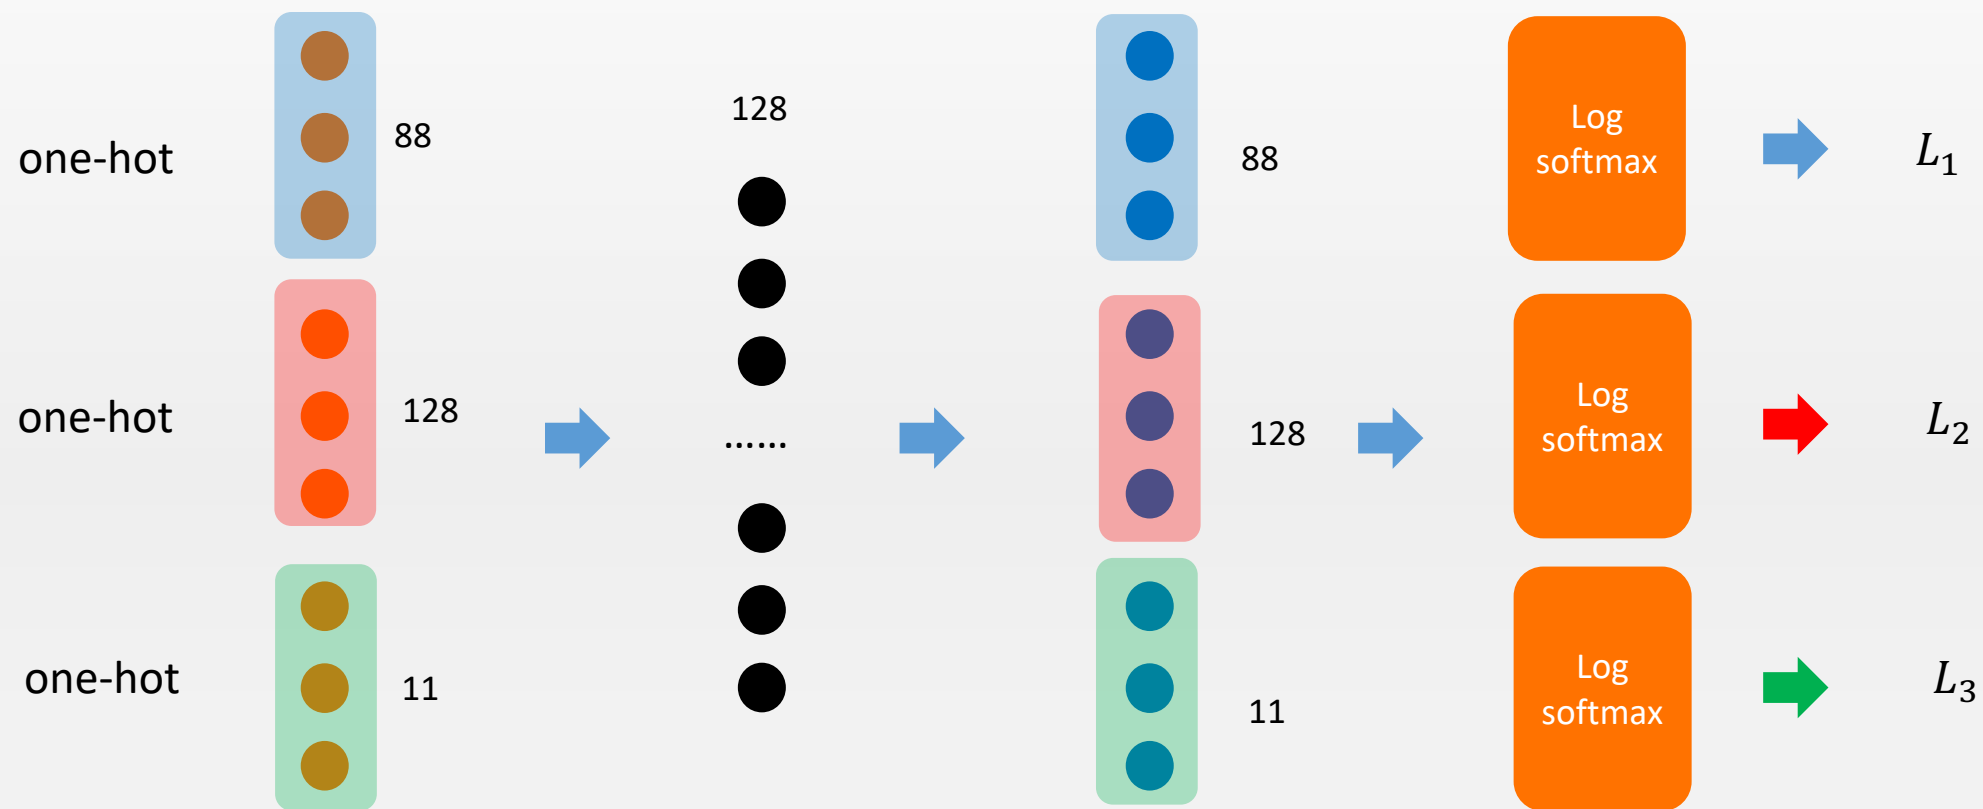
- 乐器数字接口(Musical Instrument Digital Interface,[MIDI](#)) 是20 世纪80 年代初为解决电声乐器之间的通信问题而提出的。MIDI 传输的不是声音信号, 而是音符、控制参数等指令, 它指示MIDI 设备要做什么,怎么做, 如演奏哪个音符、多大音量等。
- MIDO是一个非常方便好用的Python包, 可以直接读入midi音乐, 也可以输出midi音乐
- 关键的数据结构是一个Message列表:
- [msg1, msg2, msg3,...]
- 每个msg包括:
  - 音符 (**note**~[24,102])
  - 强度 (速度[0,128])
  - 与相对上一个音符的时间 (**time**[0,1])



## 预测问题

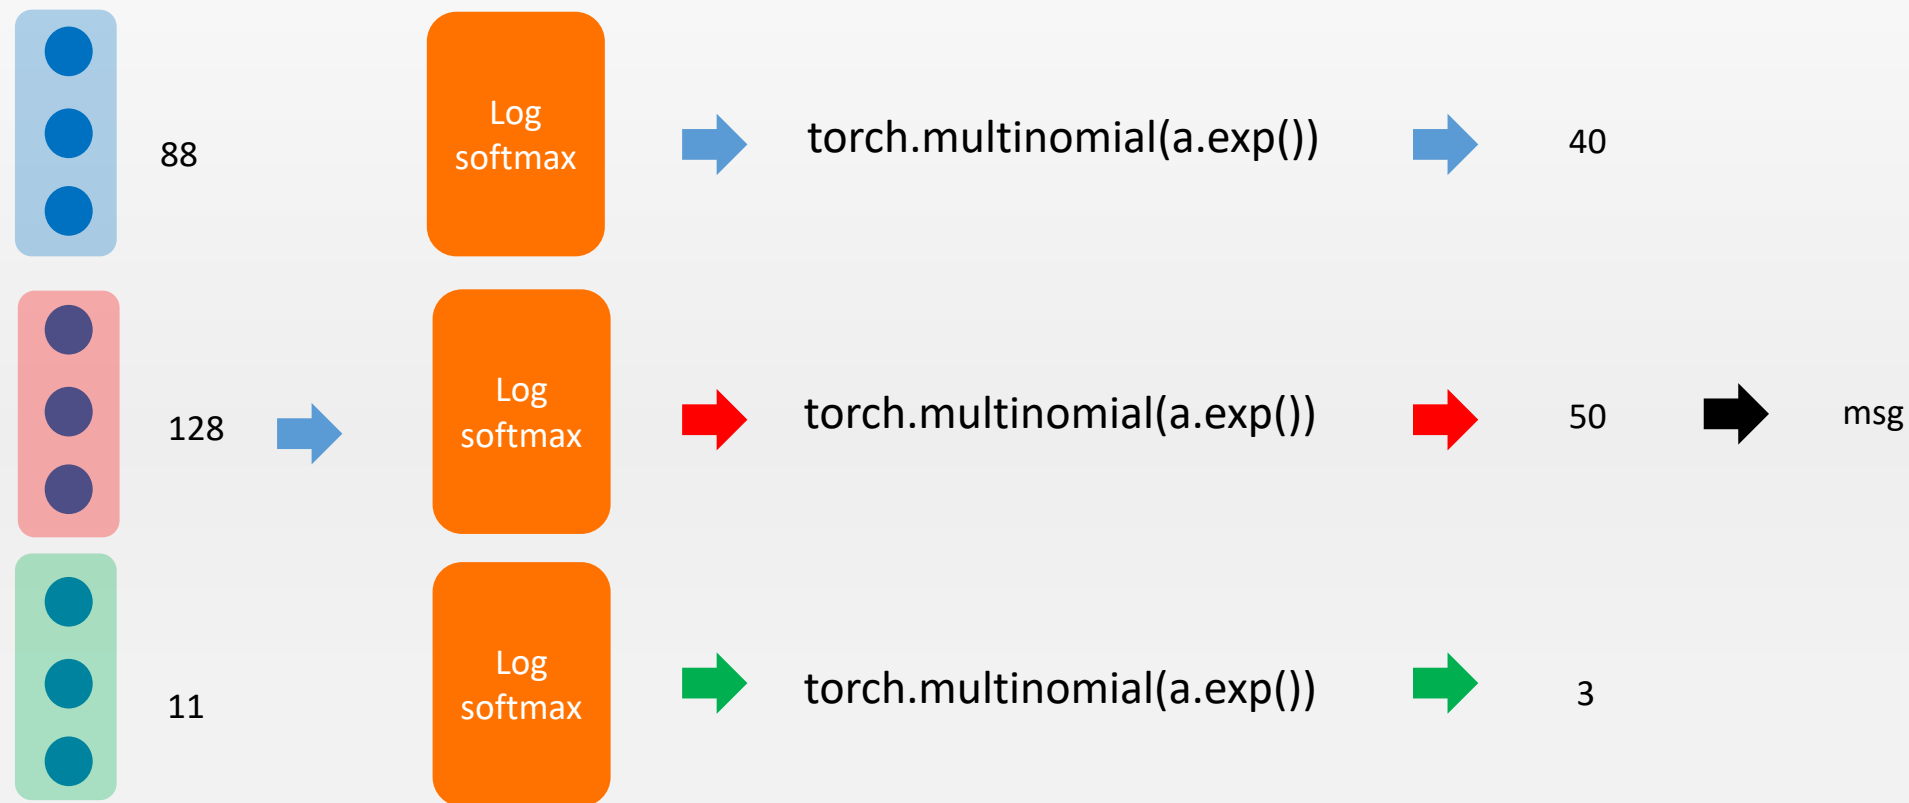
78	82	30	.....	72	71	54	43	43	54	56	78	30	
120	11	30	.....	33	22	14	126	1	0	0	12	23	0
0	1	2	.....	0	3	5	0	1	0	0	3	0	1

## 阶段I: 神经网络架构



$$L = L_1 + L_2 + L_3$$

## 阶段II: 序列生成



# 今日重点

- 如何用神经网络做序列生成？
- RNN与LSTM的工作原理
- RNN是如何记忆Pattern的？
- MIDI音乐的原理
- 如何用LSTM作曲

# 作业：名称生成器

- 请设计一个LSTM网络，要求输入一个国别，输出一个这个国别的名称

